Luka Šimek

e-mail: simek.luka@gmail.com telefon: +385 92 5028 177 website: https://tinjano.github.io GitHub: https://github.com/tinjano



Sažetak

Matematičar po obrazovanju i godinama entuzijazma. Usredotočen na statistiku i širi pojam *data science*a. Raznoliki skup teoretskih znanja i praktičnih vještina s jakim temeljima. Sposoban za razne zadatke, od prikupljanja podataka iz otvorenih izvora, preko vizualizacije do inferencijalnog i prediktivnog modeliranja.

Obrazovanje

2019.-2022. Preddiplomski studij matematike, Sveučilište u Zagrebu, Prirodoslovno-matematički fakultet

prosjek ocjena: 4.22

izborni kolegiji: Građa računala, Baze podataka, Markovljevi lanci,

Objektno programiranje (C++)

demonstrator iz Matematičke analize (1 i 2) i Programiranja (1 i 2)

2015.-2019. XV. gimnazija, Zagreb

brončana medalja na Srednjoeuropskoj matematičkoj olimpijadi (MEMO) 2017.

drugo mjesto na Državnom natjecanju iz matematike 2016.

sudjelovanje na državnim natjecanjima iz matematike, informatike, logike i fizike

Znanje i vještine

programski jezici Python

web scraping: Beautiful Soup, selectolax, requests, HTTPX, Playwright

znanstvene biblioteke: NumPy, SymPy, SciPy, statsmodels, PyMC, pandas, Polars,

scikit-learn, TensorFlow, transformers

vizualizacija: Matplotlib, seaborn

iskustvo u: SQL, R, C, C++

matematičko znanje sistematsko i intuitivno znanje analize, linearne algebre, diskretne (kombinatorne)

matematike, teorije vjerojatnosti, statistike i statističkog (strojnog) učenja

opće informatičko znanje znanje o algoritmima i strukturama podataka, iskustvo u dizajnu i implementaciji

algoritama, osnovno znanje asinkronog programiranja i računalnih mreža

ostalo JupyterLab, LaTeX, alati Linuxa, git, opće vještine rješavanja problema,

precizna i stručna komunikacija na hrvatskom i engleskom jeziku

Odabrani projekti

<u>essay-quality</u>. Inspiriran natjecanjem na Kaggle-u, cilj ovog projekta bio je predvidjeti ocjene eseja na temelju *event logova*. Izračunamo veliki broj prediktora pomoću biblioteke Polars, vizualiziramo njihovu važnost i distribucije te kreiramo dva modela: klasifikator temeljen na multinomijalnoj logističkoj regresiji i *boosted decision tree* regresor. Zatim razmatramo dodatne mogućnosti multifraktalnom analizom (MFDFA) raznih vremenskih nizova. Biblioteke: Polars, scikit-learn, XGBoost

<u>ad1</u>. Vizualizacija reklamiranja na Google-u u Hrvatskoj. Skupljamo podatke koristeći BigQuery i razmatramo razne parametre i trendove, stvarajući na kraju kvalitetne grafove spremne za prezentaciju. Biblioteke: pandas, Matplotlib.

<u>fastdice</u>. Istražujemo donošenje odluka u stohastičkom okruženju na primjeru bacanja kocaka sličnom kao u igri Jamb. Inzistirajući na brzim vektoriziranim implementacijama, kreiramo potklasu tenzora za Monte Carlo simulacije, klasu koja predstavlja Markovljev lanac i na kraju alate za računanje optimalnih strategija u Markovljevim procesima odlučivanja s dovoljno malim prostorom stanja i radnji. Biblioteke: NumPy.